

Arnaud DURAND | AI Platform Engineer

Paris, France

arnaud.durand97@gmail.com o wesper-dev.github.io
linkedin.com/in/arnaud-durand42 o github.com/Wesper-Dev

Recherche un CDI, en France ou à l'international | Disponible à partir du 16 octobre 2026

Expérience professionnelle

BPCE

avr. 2026 – oct. 2026

Stage – ingénierie plateforme IA

- Conçu la sandbox des outils d'agents d'un POC interne de runtime : confinement Docker protégeant noyau et réseau de l'hôte, avec l'équipe infra ; travail sur son architecture Kubernetes pour passer à l'échelle.
- Construit en interne un agenda sous contrainte résolu par optimisation ; sa planification, faite à la main en 1–2 jours, tombe à 1 h pour un résultat mieux optimisé.

BNP Paribas

sept. 2025 – mars 2026

Stage Data Scientist

- Ramené le traitement d'un rapport Word de 3–5 à 1–3 min par document (env. 95 % d'accord des analystes), notamment en parallélisant les appels LLM, dans une application React faite en binôme ; mise en production après comité de pilotage ; gain estimé par le chef des analystes à env. 300 jours-homme par an pour l'équipe.
- Fait tourner les outils LLM internes utilisés au quotidien par l'équipe (interface de chat, passerelle d'inférence) : hôte de staging et 75+ conteneurs Docker administrés, 600 Go de stockage récupérés.
- Branché ces outils sur Langfuse on-premise (observabilité LLM : traces, coûts, performances) ; tutoriel pour l'équipe.

Croix-Rouge française

2025

Contribution IA bénévole

- Construit avec l'équipe la couche IA d'une plateforme de formation des secouristes, utilisée par 50+ bénévoles : RAG sur un manuel de 700 pages et coach socratique ; présentée à ChangeNow et à AI for Good (2025).

Projets

droit-de-retard

2026

- Continuation personnelle d'un projet de hackathon : agent local-first qui prépare un brouillon de réclamation pour vol retardé à partir des documents du passager — le modèle extrait, une liste blanche décide, Python calcule.
- 121 tests déterministes hors ligne ; périmètre d'évaluation documenté dans le dépôt.

Pokémon × Gemma (privé)

2026

- Jusqu'où peut aller un petit modèle local ? Gemma 4 12B joue à Pokémon Émeraude via Ollama, avec une ligne d'autonomie explicite, un journal de run jamais réécrit et des ablations face à un modèle frontière.

Diary

2025

- Prototype de journal audio : enregistrement navigateur, conversion FFmpeg, API FastAPI et stockage cloud.
- Intégré l'envoi et le rapport hebdomadaire, avec consentement explicite ; React/TypeScript et Docker.

Hackathons

1re sur 12 équipes : IA & Crise, Croix-Rouge (2025) – voir Expérience

1re place : Science inFuZe (2025), track éducation – application pour promouvoir les femmes en sciences

1re place : Google Datacenter Hardware (2024) – configuration d'une baie serveur

2e place : LCL & Google Cloud (2024) – chatbot de recommandation de cartes bancaires

3e sur 20 équipes : Hackathon 54 (2024) – prototype embarqué, concept retenu pour la suite

Compétences techniques

Langages : Python, C, C++, Bash, SQL, TypeScript.

Plateforme : Linux, Docker, Kubernetes, Git, CI/CD et Langfuse.

IA appliquée : PyTorch, RAG, agents avec function calling, évaluations hors ligne, vLLM, Ollama, FastAPI.

Formation, communauté & langues

École 42 Paris, 2019–2026 — cursus informatique par projets : C/C++, UNIX/POSIX, réseau, concurrence.

GDG on Campus 42 Paris – Co-Lead Organizer depuis mai 2026 ; talk Google sur Gemini, 100+ participants.

Fitness 42 – coach depuis 3+ ans : 15+ séances données, 15 à 20 personnes par séance.

Langues : français langue maternelle ; anglais courant ; espagnol B1.